커널 변경 사항

LG전자 김준수 js1304@gmail.com


목차

- v4.20
 - Pressure Stall Information
 - TCP: switch to Early Departure Time model
 - Revisit CPU security bugs
- v5.0
 - Energy-aware scheduling
 - KASAN: software tag based mode
 - ZRAM improvements
- v5.1
 - High performance asynchronous I/O
 - Use persistent memory as RAM
 - TEO, an alternative CPU idle governor

v4.20

Pressure Stall Information (PSI)

- 시스템 자원이 경쟁 상태에 있음을 나타내는 새로운 성능지표
- 경쟁 상태로 인해 지연된 작업이 존재하는 시간 비율




• 출력 예시


some avg10=2.04 avg60=0.75 avg300=0.40 total=157656722

Pressure Stall Information (PSI)

- workload 와 CPU 로 생산성을 측정
 - SOME state: nr_delayed_tasks != 0
 - FULL state: nr_delayed_task != 0 && nr_running_tasks == 0
- 측정 하는 자원
 - CPU, MEMORY, IO
- Future work
 - Pressure stall monitor

• 네트워크 트래픽을 조절하는 새로운 모델






• 네트워크 속도의 한계

AFAP (as fast as possible)


AFAN (as fast as necessary)



• 네트워크 속도의 한계

AFAP (as fast as possible)

AFAN (as fast as necessary)




• 기존의 queue 구현에 비해 빠름


• queue 를 완전히 (backward compatible) 대체 가능

- NIC API
 - send (what) → send (what, when)

Spectre v2




 인접한 cpu의 indirect 분기를 일시적으로 제어할 수 있는 하드웨어 버그(?)를 이용해서 해커가 원하는 코드(미리 읽기 코드)로 분기하게 하여 미리 읽기를 유도한 후 캐시를 분석하여 미리 읽은 값을 찾아내는 해킹 방법




출처: kernel-dev-ko.github.io

Spectre v2




 인접한 cpu의 indirect 분기를 일시적으로 제어할 수 있는 하드웨어 버그(?)를 이용해서 해커가 원하는 코드(미리 읽기 코드)로 분기하게 하여 미리 읽기를 유도한 후 캐시를 분석하여 미리 읽은 값을 찾아내는 해킹 방법




출처: kernel-dev-ko.github.io

- retpoline
 - jmp → ret

user-space to user-space attack




• IBPB (indirect branch prediction barrier)



• IBPB (indirect branch prediction barrier)


STIBP (single thread indirect branch predictors)



v5.0


• 에너지 소모량을 최소화 하기 위한 스케쥴링 알고리즘

• ARM big.LITTLE 을 위한 스케쥴링 알고리즘




State	Сар	Pow
0	10	10
1	50	50

State	Сар	Pow
0	10	10
1	20	20
2	30	30



State	Сар	Pow
0	10	10
1	50	50

State	Сар	Pow
0	10	10
1	20	20
2	30	30
•••		




State	Сар	Pow
0	10	10
1	50	50

State	Сар	Pow
0	10	10
1	20	20
2	30	30

Compiler instrumentation

- Shadow memory
 - 할당 상태에 대한 정보


```
int a[5];
int b;
-----→ hook
b= a[5]
```




Compiler instrumentation

- Shadow memory
 - 할당 별로 tag 를 저장


```
int a[5];
int b;
-----→ hook
b= a[5]
```



•
$$x = A[14]$$



•
$$x = A[14]$$




- 동작 방법
 - ARM64 에서 지원하는 Top Byte Ignore (TBI) 기능을 이용
 - 커널 메모리(SLAB object) 할당 성공시, 반환되는 주소 top byte 에 tagging
 - shadow memory 에 tag 를 저장
 - Compiler instrumentation 으로 memory read/write instruction 앞에 추가된 hook 을 이용
 - Hook 에서 shadow memory 의 tag 와 메모리 접근에 사용된 pointer 의 tag 를 비교
 - Tag 값이 다르면, 올바르지 않은 접근

- 장점
 - 메모리 절약
 - use-after-free 를 검출하기 위해 quarantine 기능 불필요
 - memory overflow 로 다른 할당된 메모리에 접근하는 경우에도 검출
- 단점
 - CPU specific feature
 - 현재 gcc 는 지원하지 않음. Clang 7.0 이상이 요구됨
 - global/stack variable 은 지원하지 않음

ZRAM improvements

- 요약
 - zram 에 존재하는 특정 타입의 page 들을 disk 로 옮길 수 있는 기능
 - 메모리 절약 가능



ZRAM improvements

- 기반 설비
 - IDLE mark 를 위한 interface 제공
 - IDLE/HUGE page 를 선택적으로 writeback 할 수 있는 interface 제공
 - writeback throttling 기능 구현

```
while (1) {
    # mark allocated zram slot to IDLE
    echo all > /sys/block/zram0/idle

# leave system working for several hours unless there is no access for some blocks on zram
    # they are still IDLE marked pages

# write the IDLE marked slot into backing device and free the memory
    echo "idle" > /sys/block/zram0/writeback
}
```

v5.1


• 리눅스에서 asynchronous I/O 를 사용하기 위한 새로운 API


• 이전에 존재 했던 여러 가지 문제점 해결

- User-space library 제공
 - liburing

• 600 line 이 넘는 sample code

```
static int setup_ring(struct submitter *s)
                     struct io_uring_params p;
                     fd = io_uring_setup(depth, &p);
                     s \rightarrow rinq_fd = fd;
                     ptr = mmap(0, p.sq_off.array + p.sq_entries * sizeof(_u32),
                                                                PROT_READ | PROT_WRITE, MAP_SHARED | MAP_POPULATE, fd,
                                                                IORING OFF SQ RING);
                     s->sges = mmap(0, p.sq_entries * sizeof(struct io_uring_sge),
                                                                PROT_READ | PROT_WRITE, MAP_SHARED | MAP_POPULATE, fd,
                                                                IORING_OFF_SQES);
                     ptr = mmap(0, p.cq_off.cqes + p.cq_entries * sizeof(struct io_uring_cqe),
                                                                PROT_READ | PROT_WRITE, MAP_SHARED | MAP_POPULATE, fd,
                                                                IORING_OFF_CQ_RING);
```





completion queue

int io_uring_setup(int entries, struct io_uring_params *params);

- 세 개의 공간에 대한 mmap
 - submission queue
 - submission queue entries
 - complete queue


```
struct io_uring_params {
    __u32 sq_entries;
    __u32 cq_entries;
    __u32 flags;
    __u16 resv[10];
    struct io_sqring_offsets sq_off;
    struct io_cqring_offsets cq_off;
};
```

 int io_uring_enter(unsigned int fd, u32 to_submit, u32 min_complete, u32 flags);

• persistent memory 를 memory 로 사용하는 손쉬운 방법

- persistent memory
 - non-volatile
 - byte-addressable
 - load/store access
 - DRAM-like speed


Linux Kernel Architecture for PM programming



^{*} from Persistent Memory Programming, Andy Rudoff

출처: kernel-dev-ko.github.io

Linux Kernel Architecture for PM programming



^{*} from Persistent Memory Programming, Andy Rudoff

출처: kernel-dev-ko.github.io

• Memory hot-plug interface 이용 "echo dax0.0 > /sys/bus/dax/drivers/device_dax/unbind" "echo dax0.0 > /sys/bus/dax/drivers/kmem/new_id" "echo online > /sys/devices/system/memory/memoryXXX/state"

- 커널이 일반적으로 사용하는 메모리와 동일하게 인식됨
- NUMA node 로 분리하여 관리할 수 있음

Timer Events Oriented (TEO) governor

CPUIDLE governor


ladder

• menu

- TEO
 - next timer 정보를 주로 고려하여 idle 상태를 결정
 - cpuidle.governor=teo

Timer Events Oriented (TEO) governor

• menu



• TEO

